Campo	Detalle
Integrantes	**Juan Camilo Castillo Posada**
Proyecto	**Centinela Dengue: Predicción de brotes mediante enfoque multimodal (Fase 1: Línea base tabular)**
Fase	**Fase 1 · MLP**
Primer identificador de esta fase	**E-1**
Fecha de entrega	**2026/11/03**

Declaración de uso de IA

Quienes firman declaran que durante esta fase usaron las siguientes herramientas de IA generativa:

DeepSeek · Modelo V3 → para depurar el bucle de entrenamiento, sugerir la arquitectura del MLP, optimizar el umbral de decisión y estructurar la división temporal de los datos.

DeepSeek · Modelo V3 → para revisar la lógica de ingeniería de características (lags y promedios móviles) y redactar la estructura del informe técnico.

Partes del entregable redactadas o programadas sin IA: (*la lógica de descarga de la API de Socrata, la limpieza inicial de los datos de PhysioNet, la redacción de las conclusiones éticas y la selección de las métricas de evaluación clínica*).

Quienes firman declaran también que **comprenden, verificaron y pueden defende**r como propio cada artefacto entregado, que cada integrante responde en la sustentación por una parte distinta del trabajo y que esta bitácora refleja con honestidad cómo se usaron estas herramientas.

Juan Camilo Castillo Posada		**2026/11/03**

Registro de interacciones

E-1

Campo	Registro
ID	E-1
Fecha y hora	2026/10/30 13:00
Fase · paso	F1 · Paso 4 (Definición del target)
Integrante que hizo la consulta	Juan Camilo Castillo Posada

Herramienta y modelo	DeepSeek · V3
Celda o commit afectado	Celda 4 (Variables columnas_features y creación de X, y) · # E-1
Objetivo de la consulta	Resolver por qué el modelo daba un rendimiento sospechosamente alto usando el conteo actual como variable predictora.
Indicación (resumen)	"Tengo un problema, definí el target como conteo > percentil pero usé conteo como feature. ¿Está bien?"
Qué devolvió la IA	La IA identificó una fuga de información (leakage) circular y explicó que el modelo estaba haciendo trampa. Recomendó usar rezagos (lags) de semanas anteriores en lugar del conteo actual.
Datos compartidos con la IA	Solo el esquema del DataFrame y nombres de variables. Ningún dato real de salud o PII.
Decisión	Modificada
Justificación	Se acató la corrección metodológica. Predecir el presente con el presente invalida el modelo en la vida real. Se implementaron lags de 1 a 8 semanas.
Cómo se verificó	Se reemplazó conteo por conteo_lag1...conteo_lag8. El modelo pasó de métricas artificialmente perfectas a un ROC-AUC realista de 0.71.
Evidencia de origen	bitacora/E-1.png (Captura de pantalla del chat donde se explica la fuga de información).

E-2

Campo	Registro
ID	E-2
Fecha y hora	2026/10/30 13:20
Fase · paso	F1 · Paso 4 (Train/Test Split)
Integrante que hizo la consulta	Juan Camilo Castillo Posada
Herramienta y modelo	DeepSeek · V3
Celda o commit afectado	Celda 4 (División de datos) · # E-2
Objetivo de la consulta	¿Cómo dividir los datos de series temporales correctamente para el entrenamiento?
Indicación (resumen)	"Estoy usando train_test_split de sklearn para dividir los datos, ¿es correcto para este problema?"
Qué devolvió la IA	La IA alertó que train_test_split aleatorio es un error grave en series temporales (sesgo de futuro). Recomendó hacer una división temporal estricta (Entrenar con 2016-2017, validar/probar con 2018).

Datos compartidos con la IA	Esquema de las columnas ano y semana.
Decisión	Modificada
Justificación	En epidemiología, no puedes entrenar un modelo con los datos del futuro (2018) para predecir el pasado (2016). La división temporal refleja el uso real del modelo predictivo.
Cómo se verificó	Se implementaron máscaras booleanas (train_mask, val_mask, test_mask). El modelo ahora evalúa su capacidad real de generalización hacia adelante en el tiempo.
Evidencia de origen	bitacora/E-2.png (Captura de pantalla de la recomendación de división temporal).

E-3

Campo	Registro
ID	E-3
Fecha y hora	2026/11/02 12:40
Fase · paso	F1 · Paso 5 (Arquitectura y Entrenamiento)
Integrante que hizo la consulta	Juan Camilo Castillo Posada
Herramienta y modelo	DeepSeek · V3
Celda o commit afectado	Celda 5 (Clase MLP y optimizador) · # E-3
Objetivo de la consulta	Mejorar el rendimiento del modelo y evitar sobreajuste.
Indicación (resumen)	"El modelo se estanca en las métricas. ¿Cómo puedo mejorar la red neuronal y el entrenamiento?"
Qué devolvió la IA	La IA sugirió cambiar la arquitectura a una red más profunda (64-32), agregar BatchNorm1d y Dropout(0.3). También sugirió bajar el Learning Rate de Adam a 0.001 y añadir weight_decay.
Datos compartidos con la IA	Fragmentos de código del bucle de entrenamiento y shapes de los tensores.
Decisión	Aceptada
Justificación	Las mejoras propuestas son estándares de la industria para regularizar redes neuronales y estabilizar el gradiente en datos tabulares ruidosos.
Cómo se verificó	Las curvas de pérdida mostraron una convergencia más suave y el F1-Score de la clase minoritaria subió de 0.26 a 0.54.
Evidencia de origen	bitacora/E-3.png (Opcional, al ser Aceptada).

Auditoría a la IA

Tipo de auditoría (se marca una):

☑ **Real:** la IA produjo el fallo durante el proyecto.

□ **Inducida y declarada:** la IA no produjo un fallo genuino; se le pidió revisar una parte del propio código (p. ej., el bucle o la evaluación) y se auditó su respuesta. Llega como máximo al nivel Autónomo del Criterio 5.

Ficha del caso (Nivel Estratégico)

Campo	Registro
Entrada de la bitácora	E-2
Contexto	Durante la preparación del pipeline en la Fase 1, se necesitaba dividir el conjunto de datos en entrenamiento, validación y prueba para entrenar el MLP.
Qué dijo la IA	En la primera iteración del código, la IA sugirió usar la función train_test_split de Scikit-Learn con test_size=0.30 y random_state=42.
Evidencia de origen	bitacora/E-2.png (Fragmento del código original sugerido con train_test_split).
Por qué estaba mal	La división aleatoria en series temporales causa Data Leakage (Fuga de Información). Al mezclar aleatoriamente, el modelo podría entrenar con datos de la semana 40 de 2018 y validar con la semana 10 de 2016. Esto infla las métricas artificialmente porque el modelo "conoce el futuro" y no refleja un escenario de predicción real.
Cómo se detectó	Al revisar las fechas en las variables, se notó que las métricas del set de validación eran anormalmente buenas y no correspondían con la dificultad biológica de predecir un brote de dengue. Además, se contradice con la teoría de forecasting (pronóstico) de series de tiempo.
Corrección aplicada	Se reemplazó train_test_split por una división temporal estricta usando máscaras booleanas. Entrenamiento: 2016-2017; Validación: 2018 (Semanas 1-26); Test: 2018 (Semanas 27-52).
Reproducción (Nivel Estratégico)	Celda A (IA): X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42) → Arroja un AUC inflado (ej. ~0.85).
	Celda B (Corregida): Uso de train_mask temporal → Arroja un AUC más honesto y realista (ej. 0.7713).
	Semilla: 42.
Resultado de la medición	Con la división aleatoria, el modelo alcanzó un Recall de 0.75 y un AUC de ~0.88. Con la división temporal estricta

	(correcta), el Recall real cayó a 0.61 y el AUC a 0.7713. Esta caída demuestra la falsedad del primer modelo.
Lección	La IA tiende a dar soluciones genéricas (el train_test_split es el estándar para datos i.i.d., pero un error fatal para series de tiempo). Como ingenieros, debemos validar que las soluciones algorítmicas respeten la naturaleza física y temporal de los datos, y no confiar ciegamente en la primera sugerencia de la IA.