Título del proyecto	Predicción de Brotes de Dengue en Colombia mediante un Enfoque Multimodal (Fase 1: Línea Base Tabular)
Integrantes	Juan Camilo Castillo Posada
Fecha (AAAA-MM-DD)	3/11/2026
Versión	v1 en la Fase 1

1. Problema y cliente

El dengue es una arbovirosis endémica en Colombia que presenta picos epidémicos estacionales, saturando los sistemas de salud municipales y aumentando la mortalidad. El cliente objetivo de este proyecto son las Secretarías de Salud Municipales y el **Instituto Nacional de Salud (INS)**, quienes requieren herramientas de alerta temprana para optimizar la asignación de recursos (fumigación, campañas de prevención, capacidad hospitalaria). El objetivo de esta Fase 1 es construir una línea base predictiva utilizando datos tabulares históricos, que sirva como cimiento para un modelo multimodal (Fase 2) que integrará imágenes satelitales para capturar factores ambientales.

2. Datos y Acoplamiento

Se utilizaron dos fuentes primarias alineadas espacio-temporalmente para los 81 municipios de Colombia entre 2016 y 2018:

- **Rama Temporal (SIVIGILA):** Obtenida vía API de Datos Abiertos Colombia. Se agregaron los casos de dengue (código 210) por municipio, año y semana epidemiológica, totalizando 33.025 registros.
- **Rama de Imagen (PhysioNet):** Metadatos del dataset "A Multi-Modal Satellite Imagery Dataset for Public Health Analysis in Colombia" (Cajas et al., 2024), que contiene 12.636 imágenes satelitales alineadas con las semanas epidemiológicas.
- **Acoplamiento:** El merge entre ambas fuentes resultó en 32.070 registros coincidentes, demostrando una sólida alineación espaciotemporal.
- **Tratamiento:** Se aplicó una división temporal estricta (entrenamiento 2016-2017, validación y prueba en 2018) para evitar fuga de información del futuro. Se generaron variables de ingeniería (rezagos, promedios móviles, estacionalidad y contexto departamental).

3. Modelo y Entrenamiento

Se implementó un **Perceptrón Multicapa (MLP)** en PyTorch como modelo de referencia. La arquitectura consta de tres capas densas (64, 32, 1) con activación ReLU, normalización por lotes (BatchNorm) y dropout (0.3) para regularización. La función de pérdida utilizada fue BCEWithLogitsLoss con un peso positivo (pos_weight de 5.66) para mitigar el desbalanceo de clases (aproximadamente 20% de brotes). Se utilizó el optimizador Adam (tasa de aprendizaje 0.001) y un bucle de entrenamiento explícito con **parada temprana (Early Stopping)** basada en la pérdida de validación.

4. Resultados y Errores (Falsos Negativos y Falsos Positivos)

El modelo alcanzó un ROC-AUC de 0.7713 en el conjunto de prueba, superando al benchmark de Random Forest (0.7299). Se optimizó el umbral de decisión a 0.4457 para maximizar el F1-Score de la clase minoritaria (Brote).

Análisis de Errores:

- **Falsos Negativos (FN = 460):** Brotes reales que el modelo no detectó. Este es el error más crítico en salud pública, ya que implica una oportunidad perdida para intervenir. El modelo priorizó un Recall del 61% para la clase Brote.
- **Falsos Positivos (FP = 795):** Semanas sin brote que el modelo marcó como alerta. Aunque generan costos operativos innecesarios (falsas alarmas), son menos graves que un FN.

Matriz de Confusión (Umbral 0.45):

- Verdaderos Negativos (TN): **3.339**
- Falsos Positivos (FP): **795**
- Falsos Negativos (FN): **460**
- Verdaderos Positivos (TP): **729**

Las variables más predictivas fueron depto_mean_lag1 (contexto espacial), rolling_mean_4 (tendencia) y semana_sin (estacionalidad), confirmando el comportamiento del dengue.

5. Decisión Recomendada y Riesgos Éticos

Decisión Recomendada: Implementar este modelo como un sistema de alerta temprana de apoyo a la decisión, NO como un sustituto del juicio de los epidemiólogos. Dado el Recall del 61%, el modelo puede usarse para priorizar la vigilancia en municipios con alta probabilidad de brote, pero debe ser validado por un experto humano.

Riesgos Éticos y Mitigación (alineados con OMS y UNESCO):

Sesgo y Equidad: El modelo podría tener un rendimiento inferior en municipios con datos históricos escasos o de baja calidad. Mitigación: Monitorear el rendimiento por departamento y aplicar técnicas de aprendizaje con pocos datos en la Fase 2.

Transparencia y Explicabilidad: Un MLP es una "caja negra". Mitigación: Se utilizó un Random Forest como benchmark para obtener importancia de variables, y en la Fase 2 se usarán mapas de saliencia en las imágenes satelitales.

Autonomía y Supervisión Humana: La decisión final de declarar un brote debe recaer en las autoridades de salud. Mitigación: El sistema se presenta como una herramienta de screening, no de diagnóstico.

Privacidad de Datos: Los datos de SIVIGILA son agregados y no contienen información personal identificable (PII). Se cumplió con la Ley 1581 de 2012.

Sostenibilidad: El modelo es computacionalmente ligero, pero su reentrenamiento periódico requiere recursos. Mitigación: Se documentó el pipeline para su reproducibilidad.

Referencias (APA 7)

Instituto Nacional de Salud. (2026). Datos de Vigilancia en Salud Pública de Colombia [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/Salud-y-Protecci-n-Social/Datos-de-Vigilancia-en-Salud-P-blica-de-Colombia/4hyg-wa9d

Silva, J. P., et al. (2023). A Multi-Modal Satellite Imagery Dataset for Public Health Analysis in Colombia [Conjunto de datos]. PhysioNet. https://doi.org/10.13026/physionet.multimodal.1.0.0